

Guia Prático: Como Interpretar a Saída de `summary(coxph())` no R

Um roteiro de leitura do Modelo de Riscos Proporcionais de Cox para pesquisadores

Índice

1	Introdução: o que é o modelo de Cox?	1
1.1	Como o R organiza o tempo de sobrevivência	2
2	Anatomia da saída de <code>summary(coxph(...))</code>	2
2.1	Cabeçalho (<code>Call:</code>)	3
2.2	Amostra e eventos	3
2.3	Tabela de coeficientes	3
2.4	Tabela de Hazard Ratios com intervalo de confiança	4
2.5	Medidas de ajuste global	4
3	Interpretando o Hazard Ratio (HR)	4
3.1	Traduzindo o exemplo do curso	5
4	Os três testes de significância	5
4.1	Teste de Wald	5
4.2	Teste da Razão de Verossimilhança (Likelihood Ratio Test)	5
4.3	Teste de Escore (Score / log-rank test)	6
5	Intervalo de confiança e o valor de nulidade	6
6	Concordância: avaliando o poder discriminatório do modelo	6
7	Comparando modelos aninhados	7
8	Roteiro rápido de leitura	7
9	Referências	8

1 Introdução: o que é o modelo de Cox?

A função `coxph()`, do pacote `survival` do R, ajusta o **Modelo de Riscos Proporcionais de Cox** — o modelo de regressão mais utilizado em análise de sobrevivência. Ele modela o efeito de covariáveis sobre a função de risco (*hazard*) de um indivíduo:

$$\lambda(t | \mathbf{x}) = \lambda_0(t) \exp(x_1\beta_1 + x_2\beta_2 + \dots + x_p\beta_p)$$

Três ideias sustentam esse modelo e ajudam a entender por que ele é chamado de **semiparamétrico**:

- $\lambda_0(t)$ é o **risco basal** — não se assume nenhuma distribuição estatística para ele ao longo do tempo (parte não paramétrica).

- As covariáveis entram de forma **multiplicativa** sobre o risco basal — essa é a parte paramétrica do modelo.
- Pressuposto central: a razão de riscos entre dois indivíduos **não varia ao longo do tempo** — por isso o nome “riscos proporcionais”. Este pressuposto deve sempre ser verificado (gráficos de Kaplan-Meier estratificados, resíduos de Schoenfeld — ver capítulo sobre análise de resíduos).

Os coeficientes β são estimados por **verossimilhança parcial**, um método que, a cada tempo de evento, usa apenas a informação dos indivíduos ainda sob risco naquele momento — de forma semelhante à lógica do estimador de Kaplan-Meier.

1.1 Como o R organiza o tempo de sobrevivência

Antes de ajustar o modelo, o R precisa de um objeto que combine, em uma única variável, o tempo de acompanhamento e o indicador de evento. Isso é feito com a função `Surv()`:

```
library(survival)

tmo <- read.table("tmoclas.dat", header = TRUE)
tmo$sexo <- factor(tmo$sexo)

y <- Surv(tmo$os, tmo$status)
```

⚠ Atenção a um erro comum de leitura

A **primeira variável dentro de `Surv()` é o TEMPO**, não o evento. No exemplo acima, `os` é o tempo (em dias) até o óbito ou até a censura, e `status` é o indicador de evento (1 = óbito, 0 = censura). O evento em si nunca é a variável de tempo — é sempre a variável binária de status.

2 Anatomia da saída de `summary(coxph(...))`

Vamos usar como exemplo de referência o modelo abaixo, ajustado com as variáveis `idade` e `sexo`:

```
mod1 <- coxph(y ~ idade + sexo, data = tmo)
summary(mod1)
```

Call:

```
coxph(formula = y ~ idade + sexo, data = tmo)
```

n= 96, number of events= 49

	coef	exp(coef)	se(coef)	z	Pr(> z)
idade	-0.02167	0.97857	0.01399	-1.548	0.122
sexo2	-0.37649	0.68626	0.32120	-1.172	0.241

```

      exp(coef) exp(-coef) lower .95 upper .95
idade    0.9786    1.022    0.9521    1.006
sexo2    0.6863    1.457    0.3657    1.288

Concordance= 0.568 (se = 0.047 )
Likelihood ratio test= 2.92 on 2 df,  p=0.2
Wald test              = 2.85 on 2 df,  p=0.2
Score (logrank) test = 2.85 on 2 df,  p=0.2

```

A leitura dessa saída pode ser dividida em cinco blocos.

2.1 Cabeçalho (**Call:**)

O R apenas repete o comando que gerou o modelo — útil para conferir se a fórmula e o banco de dados usados foram realmente os pretendidos.

2.2 Amostra e eventos

```
n= 96, number of events= 49
```

- **n**: número total de observações (pacientes) que entraram efetivamente no modelo.
- **number of events**: quantas dessas observações tiveram o evento observado (ex.: óbito). As demais foram censuradas.

Recomendação

Sempre confira esse número primeiro. Se **n** for menor que o total de linhas do banco de dados, é sinal de que o R removeu automaticamente observações com valores faltantes (**NA**) em alguma covariável — o que pode comprometer a comparação entre modelos aninhados com conjuntos de variáveis diferentes (ver Seção 7).

2.3 Tabela de coeficientes

Coluna	O que é	Como usar
coef	Coefficiente da regressão de Cox (log do hazard ratio)	Sinal negativo = reduz o risco; positivo = aumenta o risco
exp(coef)	Hazard Ratio (HR) — exponencial do coeficiente	HR > 1 = fator de risco; HR < 1 = fator de proteção; HR = 1 = sem efeito
se(coef)	Erro-padrão do coeficiente	Quanto menor, mais precisa a estimativa
z	Estatística do Teste de Wald : $z = \hat{\beta} / \text{ep}(\hat{\beta})$	Usada para testar $H_0 : \beta = 0$

Coluna	O que é	Como usar
<code>Pr(> z)</code>	p-valor do teste de Wald	Se $< 0,05$, a variável é considerada significativa

2.4 Tabela de Hazard Ratios com intervalo de confiança

	<code>exp(coef)</code>	<code>exp(-coef)</code>	<code>lower .95</code>	<code>upper .95</code>
idade	0.9786	1.022	0.9521	1.006
sexo2	0.6863	1.457	0.3657	1.288

- `exp(coef)`: o hazard ratio (repetido da tabela anterior).
- `exp(-coef)`: o inverso do HR — útil para inverter a direção da comparação entre os grupos.
- `lower .95 / upper .95`: limites do intervalo de confiança de 95% do hazard ratio.

2.5 Medidas de ajuste global

Concordance= 0.568 (se = 0.047)
Likelihood ratio test= 2.92 on 2 df, p=0.2
Wald test = 2.85 on 2 df, p=0.2
Score (logrank) test = 2.85 on 2 df, p=0.2

Essas quatro linhas resumem a qualidade do modelo **como um todo** (e não de uma variável isolada). São discutidas em detalhe nas seções seguintes.

3 Interpretando o Hazard Ratio (HR)

O HR = `exp(coef)` é a informação mais importante da tabela de coeficientes. Ele expressa a razão entre o risco instantâneo de dois indivíduos que diferem em uma unidade na covariável, mantendo as demais fixas.

Valor do HR	Interpretação
HR = 1	Nenhum efeito da covariável sobre o risco (valor de nulidade)
HR > 1	Fator de risco — a covariável aumenta o risco do evento
HR < 1	Fator de proteção — a covariável reduz o risco do evento

Applied Survival Analysis (Hosmer, Lemeshow & May) traz um exemplo clássico: em um estudo com HR = 1,74 para sexo (feminino vs. masculino), a interpretação correta é que mulheres morrem a uma taxa cerca de 1,74 vezes maior que a dos homens ao longo do período de estudo. Uma forma alternativa — e, segundo os autores, muitas vezes mais compreensível — é expressar o HR como percentual de mudança em relação ao valor de nulidade (1):

“a taxa de óbito entre mulheres é 74% maior do que entre homens” (em vez de “1,74 vezes maior”)

A mesma lógica se aplica a efeitos protetores ($HR < 1$) — os autores destacam que pesquisadores costumam ter mais dificuldade para interpretar esse caso. Um $HR = 0,505$, por exemplo, pode ser lido de duas formas equivalentes:

- “A taxa de progressão da doença no grupo tratado é 0,505 vezes a do grupo controle”; ou
- “A taxa de progressão da doença no grupo tratado é 49,5% menor do que no grupo controle”.

3.1 Traduzindo o exemplo do curso

idade: $HR = 0,9786$. Como o HR é menor que 1, a idade atua como um discreto fator de **proteção** neste modelo — a cada ano de idade a mais, o risco de óbito é multiplicado por 0,9786 (redução de ~2,1%). Porém, $z = -1,548$ e $p = 0,122$ (acima de 0,05) — não há evidência estatística suficiente de que esse efeito exista de fato na população.

sexo2: $HR = 0,6863$, também menor que 1, sugerindo ~31% menos risco no grupo “sexo2” em relação à categoria de referência. Mas $z = -1,172$ e $p = 0,241$ — **não significativo**.

i Nota

O R nomeia a linha `sexo2` porque `sexo` foi transformado em `factor()`. O R sempre usa o primeiro nível como categoria de referência e cria uma linha para cada nível seguinte. Para saber qual nível é a referência, use `levels(tmo$sexo)`.

4 Os três testes de significância

O R reporta três testes diferentes para avaliar a significância de coeficientes e de modelos. Todos testam, em essência, a mesma hipótese nula, mas usam abordagens matemáticas distintas — e podem, em amostras pequenas, apontar conclusões ligeiramente diferentes.

4.1 Teste de Wald

Usado para cada coeficiente individualmente (coluna $z / Pr(>|z|)$):

$$H_0 : \beta_j = 0 \quad z = \hat{\beta}_j / ep(\hat{\beta}_j)$$

É simplesmente o coeficiente dividido pelo seu erro-padrão. Quanto mais distante de zero, mais improvável é que o verdadeiro efeito seja nulo. Alguns pacotes (como o SAS) reportam o quadrado dessa estatística, que segue distribuição qui-quadrado com 1 grau de liberdade — resultado equivalente.

4.2 Teste da Razão de Verossimilhança (Likelihood Ratio Test)

Compara o modelo ajustado com um modelo reduzido (ou nulo):

$$H_0 : Mod_{maior} = Mod_{menor} \quad RV = 2(l_{maior} - l_{menor}) \sim \chi^2_{(l-k)}$$

É o teste recomendado para comparar modelos aninhados (ver Seção 7), e costuma ser mais robusto que o teste de Wald quando o número de observações é pequeno. Em amostras grandes, os dois testes tendem a convergir para resultados assintoticamente equivalentes.

4.3 Teste de Escore (Score / log-rank test)

Baseado na derivada da log-verossimilhança parcial avaliada em $\beta = 0$. Também segue distribuição normal padrão sob a hipótese nula. Quando o modelo tem apenas uma covariável categórica, esse teste coincide com o teste log-rank já conhecido da análise não paramétrica (Kaplan-Meier).

💡 Quando os três testes divergem

É comum, especialmente perto do limiar de significância ($p \approx 0,05$), que os três testes apontem conclusões ligeiramente diferentes. A recomendação de Hosmer, Lemeshow e May é **reportar todos os resultados obtidos**, permitindo que o leitor avalie as diferentes conclusões dentro do contexto de seus próprios objetivos de pesquisa.

5 Intervalo de confiança e o valor de nulidade

Para o hazard ratio, o **valor de nulidade é sempre 1** — porque $HR = 1$ significa nenhuma diferença de risco entre os grupos comparados. As hipóteses do teste são:

$$H_0 : HR = 1 \quad (\text{sem efeito}) \quad H_1 : HR \neq 1 \quad (\text{há efeito})$$

! Regra prática

Se o intervalo de confiança de 95% do HR **não contém o valor 1**, rejeita-se H_0 com 95% de confiança — equivalente a $p < 0,05$ no teste de Wald. Se o intervalo **contém o 1**, a variável não é considerada significativa.

No exemplo do curso, os intervalos de `idade` (0,9521 – 1,006) e `sexo2` (0,3657 – 1,288) contêm o valor 1 — coerente com os p-valores de 0,122 e 0,241 vistos anteriormente. São duas formas diferentes de chegar exatamente à mesma conclusão.

6 Concordância: avaliando o poder discriminatório do modelo

A concordância é uma medida global de ajuste usada quando o objetivo do modelo é **prever risco**. Ela avalia a capacidade do modelo de ordenar corretamente os indivíduos por risco — de forma análoga à área sob a curva ROC (AUC) em regressão logística.

Concordância (c)	Poder discriminatório
$0,3 < c < 0,4$	Baixo
$c = 0,5$	Equivalente ao acaso
$0,6 \leq c < 0,7$	Comum

Concordância (c)	Poder discriminatório
$0,7 \leq c < 0,8$	Muito bom
$0,8 \leq c < 0,9$	Excelente

No exemplo do curso, $c = 0,568$ está bem próximo de 0,5 (chute aleatório) — o poder discriminatório do modelo é **fraco**.

7 Comparando modelos aninhados

Para decidir se novas covariáveis melhoram significativamente o modelo, usa-se o teste da razão de verossimilhança entre modelos aninhados, via `anova()`:

```
mod2 <- coxph(y ~ idade + sexo + fase, data = tmo)
mod3 <- coxph(y ~ idade + sexo + fase + deag, data = tmo)
mod4 <- coxph(y ~ idade + sexo + fase + deag + decr, data = tmo)

anova(mod1, mod2, mod3, mod4, test = "Chisq")
```

```
Analysis of Deviance Table
Cox model: response is y
Model 1: ~ idade + sexo
Model 2: ~ idade + sexo + fase
Model 3: ~ idade + sexo + fase + deag
Model 4: ~ idade + sexo + fase + deag + decr
    loglik  Chisq Df P(>|Chi|)
1 -201.94
2 -194.70 14.486  2 0.0007152 ***
3 -188.15 13.109  1 0.0002939 ***
4 -183.07 10.152  1 0.0014413 **
```

Cuidados importantes ao usar essa comparação:

- Os modelos precisam ser **aninhados** (um contido no outro) e ajustados sobre o **mesmo conjunto de observações** (mesmo n).
- Não é possível comparar diretamente modelos estratificados com modelos não estratificados.
- Se houver valores faltantes em alguma covariável, os modelos podem perder comparabilidade — use `complete.cases()` para garantir que todos sejam ajustados sobre exatamente as mesmas observações.
- Em amostras pequenas, a análise pela função desvio (razão de verossimilhança) tende a ser mais robusta do que o teste de Wald equivalente.

8 Roteiro rápido de leitura

Para qualquer saída de `summary(coxph(...))`, siga esta sequência:

1. Confirme `n` e `number of events` — a amostra está completa, sem perda inesperada de observações?
2. Para cada covariável, leia `exp(coef)` — é o hazard ratio: acima de 1 indica risco, abaixo de 1 indica proteção.
3. Verifique a significância pelo teste de Wald (`z / Pr(>|z|)`) ou pelo intervalo de confiança de 95% do HR — lembrando que o valor de nulidade é 1.
4. Avalie a **Concordância**, usando a tabela de referência acima, para julgar o poder discriminatório do modelo.
5. Observe os testes globais (razão de verossimilhança, Wald, escore/log-rank) — o modelo completo é melhor do que o modelo nulo?
6. Ao comparar modelos aninhados, use `anova(..., test = "Chisq")` — e confirme que todos foram ajustados sobre o mesmo `n`.
7. Antes de reportar os resultados, verifique o pressuposto de riscos proporcionais (resíduos de Schoenfeld).

9 Referências

Disciplina: Introdução à Análise de Sobrevivência — 2026

CARVALHO, Marília Sá; ANDREOZZI, Valeska Lima; CODEÇO, Claudia Torres; BARBOSA, Maria Tereza Serrano; SHIMAKURA, Silvia Emiko; CAMPOS, Dayse. **Análise de sobrevivência: teoria e aplicações em saúde**. 2. ed. Rio de Janeiro: Editora Fiocruz, 2011.

COLOSIMO, Enrico Antônio; GIOLO, Suely Ruiz. **Análise de sobrevivência aplicada**. São Paulo: Edgard Blücher, 2006.

FREITAS, Marta Afonso; COLOSIMO, Enrico Antônio. **Confiabilidade: análise de tempo de falha e testes de vida acelerados**. Belo Horizonte: Fundação Christiano Ottoni, Escola de Engenharia da UFMG, 1997.

HOSMER, David W.; LEMESHOW, Stanley; MAY, Susanne. **Applied survival analysis: regression modeling of time-to-event data**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2008. (Wiley Series in Probability and Statistics).

Anderson Lineu

Contato: andersonlineu@gmail.com

GitHub: <https://github.com/andersonlineu>